

Análise Estatística de Dados Automotivos: Um Estudo Descritivo do Cars Dataset 2025

Juliana Miranda Bosio, Lucas Furlanetto Pascoali, Vinícios Rosa Buzzi

¹Departamento de Informática e Estatística – Universidade Federal de Santa Catarina
Caixa Postal 5094 – 88035-972 – Florianópolis – SC – Brazil

1. Introdução

O mercado automotivo contemporâneo é caracterizado por uma vasta diversidade de modelos, tecnologias e faixas de preço. A decisão de compra de um consumidor, assim como a estratégia de precificação de um fabricante, é influenciada por uma complexa interação de fatores, desde a potência do motor até o prestígio da marca. Este estudo utiliza técnicas de análise exploratória de dados [Tukey 1977] para quantificar e compreender as principais relações que governam este cenário, focando em como os atributos técnicos de um veículo se refletem em seu valor de mercado e em sua performance.

A base para esta investigação é um conjunto de dados obtido na plataforma Kaggle, intitulado Cars Dataset 2025 [Malik 2025]. Este dataset consolida as especificações de centenas de veículos, fornecendo um campo rico para a aplicação de métodos estatísticos.

O objetivo central é responder a perguntas-chave do setor:

- Qual é o real impacto das especificações do carro, como tipo do motor e cavalos de potência, no preço final de um veículo?
- Qual o preço médio de um carro por marca?
- Qual a relação entre velocidade máxima e desempenho (tempo para chegar de 0 a 100 km/h)?

Adicionalmente, busca-se explorar o trade-off entre utilidade e esportividade, analisando como atributos familiares, como o número de assentos, se correlacionam com indicadores de alto desempenho. Ao final, este trabalho visa oferecer um panorama claro, baseado em evidências, dos fatores que mais contribuem para a configuração do mercado automotivo, fornecendo insights sobre a estrutura de preços e as tendências de engenharia do setor.

2. Materiais e Métodos

Para a análise, o estudo concentrou-se em um subconjunto específico de variáveis. Foram selecionados os atributos considerados cruciais para quantificar as correlações entre as características técnicas dos automóveis (como motor e potência) e seus principais indicadores de valor e performance.

2.1. Tratamento e Preparação dos Dados

Antes de iniciar a análise exploratória, o dataset original passou por um processo de limpeza e preparação para garantir a qualidade e a consistência dos dados. As seguintes etapas foram executadas:

- **Tratamento de Valores Ausentes:** A integridade do dataset foi verificada, e optou-se pela remoção completa de registros que apresentassem dados faltantes em qualquer uma das colunas selecionadas para o estudo. Este procedimento resultou em um dataset final com

1107 observações, garantindo que todas as análises subsequentes fossem realizadas sobre um conjunto de dados completo.

- **Conversão de Tipos:** As colunas de natureza quantitativa (como preço, potência e número de assentos) foram convertidas de seu formato original de texto (string) para um formato numérico, permitindo a aplicação de operações matemáticas e estatísticas.
- **Normalização da Variável “Motor”:** A coluna original “motor” apresentava alta granularidade e falta de padronização. Para viabilizar uma análise consistente, foi criada uma nova variável qualitativa, “tipo_de_motor”, que agrupa e normaliza os registros em um conjunto de categorias predefinidas: i2, i3, i4, v6, v8, v10, v12, w16, vr6, 4 cilindradas, flat-4, flat-6, boxer-4, 3 cilindradas, mpfi, PMSM, hybrid, electric e Outros.

2.2. Descrição das Variáveis

2.2.1. Marca

- **Classificação:** Variável qualitativa nominal.
- **Descrição:** Indica o fabricante do veículo (ex: Ford, Toyota, BMW). Refere-se à coluna *Company Name*.
- **Motivo de escolha:** Essencial para investigar o impacto do prestígio e do posicionamento de mercado no preço dos veículos, fundamentando uma de nossas principais hipóteses. Além disso, permite ao leitor analisar os resultados de acordo com a marca de interesse.

2.2.2. Tipo de Motor

- **Classificação:** Variável qualitativa nominal.
- **Descrição:** Categoria padronizada do motor, derivada da coluna original “motor” (*Engine*) conforme descrito na etapa de preparação.
- **Motivo de escolha:** Permite analisar de forma clara e objetiva a influência da motorização no preço e no desempenho dos veículos.

2.2.3. Preço

- **Classificação:** Variável quantitativa contínua.
- **Descrição:** Preço de Varejo Sugerido pelo Fabricante, em dólares (USD). Refere-se à coluna *Price*.
- **Motivo de escolha:** Principal variável-alvo para os modelos de precificação e análises de valor.

2.2.4. Desempenho

- **Classificação:** Variável quantitativa contínua.
- **Descrição:** Tempo, em segundos, que um carro leva para acelerar de 0 a 100 km/h, representado pela coluna *Performance*.
- **Motivo de escolha:** Permite comparações diretas com características como potência e número de assentos, facilitando a análise dos resultados.

2.2.5. Cavalos de Potência

- **Classificação:** Variável quantitativa contínua.
- **Descrição:** Medida da potência do motor em cavalos-força (HP), referindo-se à coluna *HorsePower*.
- **Motivo de escolha:** Principal indicador de desempenho do veículo, fundamental para validar hipóteses relacionadas à performance.

2.2.6. Número de Bancos

- **Classificação:** Variável quantitativa discreta.
- **Descrição:** Quantidade de assentos disponíveis no veículo. Refere-se à coluna *Seats*.
- **Motivo de escolha:** Utilizada para medir o perfil de utilidade do carro (familiar vs. esportivo), permitindo analisar a relação entre funcionalidade e desempenho.

2.2.7. Velocidade Total

- **Classificação:** Variável quantitativa contínua.
- **Descrição:** Velocidade máxima que o carro consegue atingir, referindo-se à coluna *Total Speed*.
- **Motivo de escolha:** Permite análises de correlação com a potência e o desempenho, aprofundando a compreensão sobre como a capacidade do motor se traduz em performance.

3. Resultados e Discussões

Nesta seção, são apresentados os resultados obtidos a partir da análise estatística do dataset. A apresentação está dividida em três partes: análise descritiva das variáveis qualitativas, quantitativas e bivariada.

3.1. Análise Descritiva das Variáveis Qualitativas

3.1.1. Distribuição de Marcas de Veículos

A análise da composição do dataset inicia-se com o estudo da variável qualitativa *marca*. Conforme detalhado na Tabela 1 no Anexo B, a frequência absoluta (a contagem de modelos por fabricante) é fundamental para entender o perfil dos dados e o peso que cada um terá nas análises subsequentes.

Observa-se que a marca **Nissan** é a mais frequente no conjunto de dados, com 158 modelos, indicando uma forte presença de seu portfólio. Logo em seguida, nota-se um agrupamento proeminente de marcas alemãs, japonesas e coreanas no *top 5*. Juntas, essas marcas compõem uma parcela substancial da amostra, o que pode influenciar as médias gerais do preço e da potência.

A presença de fabricantes de grande volume, como **Chevrolet**, **Toyota** e **Volkswagen**, garante a heterogeneidade do dataset, permitindo que a análise contemple uma gama variada de segmentos de mercado, do popular ao luxo. A distribuição apresentada na tabela sugere, portanto, que o dataset é robusto para análises comparativas entre diferentes nichos da indústria automotiva.

3.1.2. Distribuição de Tipo de Motor

O gráfico da Figura 1 exibe a frequência dos tipos de motores nos carros do dataset. É possível observar que as categorias mais comuns são “i4”, “v6”, “v8”, “electric”, “Outros” e “hybrid”. A seguir, uma descrição detalhada para cada categoria:




Figura 1. Distribuição dos tipos de motores nos veículos do dataset

- **i4:** abreviação de Inline-4, representa um motor de 4 cilindros dispostos em linha. É a configuração mais comum em carros de passeio por seu equilíbrio entre eficiência, custo e performance.
- **v6:** motor de 6 cilindros dispostos em formato de “V”. Oferece mais potência e suavidade que um motor i4, sendo comum em sedãs médios/grandes e SUVs.
- **v8:** motor de 8 cilindros em “V”, conhecido pela alta potência e torque, frequentemente utilizado em carros esportivos (muscle cars), picapes grandes e veículos de luxo.
- **electric:** contém todos os tipos de motores elétricos, incluindo PMSMs.
- **Outros:** categoria residual utilizada para agrupar motores com descrições raras e/ou que não se encaixaram nas demais categorias durante a normalização.
- **hybrid:** contém todos os tipos de motores híbridos.
- **4 cilindradas:** termo genérico para motores de 4 cilindros, utilizado nos casos em que a descrição original dos dados não especificava a configuração (em linha, boxer, etc.).
- **v12:** motor de 12 cilindros em “V”, configuração rara associada a supercarros e veículos de altíssimo luxo.
- **i3:** motor de 3 cilindros em linha, comum em carros compactos modernos, focado em baixo consumo de combustível e baixas emissões.
- **flat-6:** motor de 6 cilindros com pistões opostos horizontalmente, famoso por equipar carros da Porsche e oferecer um centro de gravidade baixo.
- **i6:** abreviação para Inline-6, motor de 6 cilindros em linha, famoso pelo funcionamento suave e balanceamento natural, muito utilizado por marcas como BMW.
- **v10:** motor de 10 cilindros em “V”, configuração de alto desempenho encontrada em supercarros como Lamborghini Huracán e Audi R8.
- **w16:** motor com 16 cilindros em uma rara configuração “W”, utilizado em supercarros da Bugatti.
- **3 cilindradas:** termo genérico para motores de 3 cilindros, similar à categoria “4 cilindradas”.
- **i2:** motor de 2 cilindros em linha, muito raro em carros, mais comum em motocicletas ou microcarros urbanos.
- **flat-4:** motor de 4 cilindros opostos horizontalmente, configuração característica de marcas como Subaru.

- **boxer-4:** motor de 4 cilindros, similar ao flat-4, porém com bielas de êmbolos opostos não compartilhando ligação à cambota.
- **vr6:** motor de 6 cilindros com um “V” de ângulo muito fechado (geralmente 15°), tecnologia da Volkswagen que combina tamanho compacto de um motor em linha com a performance de um V6.

3.2. Análise Descritiva das Variáveis Quantitativas

3.2.1. Análise da Variável Preço em Dólares

Devido à ampla variação de preços (de dezenas de milhares a mais de 10 milhões de dólares), utilizou-se uma escala logarítmica no eixo X do boxplot mostrado na Figura 2. Essa transformação permite visualizar de forma clara a distribuição dos dados, comprimindo os valores extremos sem distorcer a interpretação dos resultados.




Figura 2. Distribuição das Marcas em escala logarítmica do preço

O boxplot do preço dos veículos, representado em escala logarítmica, mostra que a maior parte dos carros de 2025 está concentrada em uma faixa entre aproximadamente 30 mil e 300 mil dólares. A mediana e a média são bastante diferentes, indicando uma distribuição assimétrica com cauda à direita. Essa assimetria é causada por um pequeno número de veículos de luxo e superesportivos com preços superiores a 1 milhão de dólares, representados como outliers. A escala logarítmica foi utilizada para permitir a visualização adequada dessa grande variação nos valores.

3.2.2. Análise da Variável Desempenho

A análise descritiva do tempo de aceleração de 0 a 100 km/h, apresentado na Figura 3, mostra que o valor mínimo é de 1,1 s, enquanto o máximo chega a 31,8 s, evidenciando a ampla variedade de desempenho entre os veículos do conjunto de dados. A mediana de 16,1 s e a média de 16,15 s indicam que, em média, os carros levam cerca de 16 segundos para atingir 100 km/h.




Figura 3. Distribuição do tempo de aceleração de 0 a 100 km/h dos veículos do conjunto de dados

Além disso, 25% dos modelos mais rápidos completam essa aceleração em até 8,4 s, enquanto 75% o fazem em até 23,9 s. A distribuição do tempo de aceleração apresentou-se relativamente uniforme, com frequências semelhantes em todas as faixas de desempenho. Esse resultado indica uma ampla diversidade de modelos no conjunto de dados, abrangendo desde veículos esportivos de alta performance (2–4 s) até automóveis convencionais e utilitários com tempos acima de 20 s. A ausência de concentração em faixas específicas mostra que a variável *desempenho* está distribuída de maneira equilibrada entre as diferentes categorias de carros.

3.2.3. Análise da Variável Cavalos de Potência

O histograma da distribuição de potência, apresentado na Figura 4, revela uma forte assimetria à direita, indicando que a grande maioria dos veículos no dataset se concentra nas faixas de potência mais baixas e moderadas.

Utilizando uma largura de faixa de 20 HP, o gráfico mostra que o pico de frequência, ou seja, a faixa com o maior número de carros, está no intervalo entre 160 e 200 cavalos. A partir dos 300 HP, a contagem de veículos por intervalo diminui drasticamente, formando uma "cauda longa" que se estende até potências superiores a 700 HP. Este padrão sugere que a amostra é composta majoritariamente por carros de passeio convencionais, com uma presença minoritária, porém notável, de modelos esportivos e de alto desempenho.




Figura 4. Distribuição dos veículos do conjunto de dados por cavalos de potência (HP)

3.2.4. Análise da Variável Número de Bancos

O Gráfico 5 ilustra a distribuição de frequência da variável quantitativa discreta *número de bancos*. Esta análise é fundamental para compreender a vocação funcional dos veículos da amostra, segmentando-os de acordo com sua capacidade de passageiros.




Figura 5. Distribuição do Número de Assentos

A visualização dos dados aponta de maneira clara que a configuração de **cinco assentos** é a mais predominante, constituindo a moda da amostra, com frequência superior a 600 modelos. Este resultado é esperado, uma vez que reflete o padrão global da indústria automotiva para veículos de passeio, como sedans, hatchbacks e a maioria dos SUVs, que visam atender às necessidades familiares.

Os segmentos seguintes em representatividade são os veículos de **4 e 2 assentos**. O primeiro grupo geralmente inclui carros compactos e modelos *coupé*, enquanto o segundo é característico de carros esportivos e alguns veículos comerciais, representando um nicho focado em performance ou trabalho em detrimento da capacidade.

3.2.5. Velocidade Máxima

A variável *velocidade máxima*, apresentada no Gráfico 6, é um dos indicadores de performance mais emblemáticos da indústria automotiva. A distribuição de frequência exibe um comportamento multimodal, ou seja, com múltiplos picos, indicando a existência de diferentes segmentos de veículos. O primeiro agrupamento significativo ocorre na faixa de 150 a 200 km/h, que corresponde ao desempenho de veículos convencionais, nos quais a velocidade máxima não é o principal atrativo.




Figura 6. Densidade da Velocidade Máxima

O aspecto mais notável do gráfico é o pico proeminente e agudo localizado exatamente em **250 km/h**. Este valor não representa uma coincidência, mas sim um padrão industrial, principalmente entre fabricantes alemães de carros de alta performance (como Audi, BMW e Mercedes-Benz), que tradicionalmente limitam eletronicamente a velocidade de seus veículos a este número [DeMuro 2018].

Além do limite de 250 km/h, a distribuição se estende em uma cauda longa à direita, englobando o segmento de supercarros, no qual a velocidade máxima é um diferencial competitivo e, portanto, não é limitada.

3.3. Análise Bivariada

3.3.1. Relação entre Marca e Preço

A marca de um veículo é um dos fatores mais determinantes de seu valor de mercado, encapsulando não apenas a engenharia e a qualidade de construção, mas também o prestígio, a exclusividade e o posicionamento no mercado. A análise do preço médio por marca, ilustrada na Figura 7, revela uma hierarquia de preços clara e uma disparidade expressiva entre os segmentos de luxo/hipercarros e os de consumo em massa.




Figura 7. Gráfico de barras exibindo o preço médio dos veículos em USD, agrupados por marca.

No topo do espectro, a **Bugatti** se destaca como um caso extremo, com um preço médio de aproximadamente \$5,87 milhões, consolidando sua posição no nicho de hiper carros, onde a exclusividade e o desempenho máximo justificam valores exponenciais. Logo abaixo, um grupo de marcas de alto luxo e super carros, como **Aston Martin** (\$752.948), **Lamborghini** (\$650.083), **Ferrari** (\$512.222), **Rolls Royce** e **Bentley**, também apresentam preços médios significativamente elevados, variando de \$300.000 a mais de \$750.000.

Em um patamar intermediário de luxo, marcas como **Porsche** (\$138.396), **Tesla** (\$97.083) e **Mercedes** (\$84.150) demonstram um valor médio robusto, embora consideravelmente mais acessível que o segmento superior.

Finalmente, a maior parte das marcas analisadas se concentra em uma faixa de preço abaixo de \$70.000, atendendo ao mercado de consumo geral. Neste grupo, encontram-se desde marcas premium como **BMW** (\$67.317) e **Audi** (\$82.671) até fabricantes de grande volume como **Toyota** (\$38.789), **Ford** (\$63.259), **Honda** (\$29.364) e **Hyundai** (\$33.063). A variação de preço dentro deste último grupo é muito menor em comparação com a vasta diferença observada nos segmentos de luxo.

Esta análise confirma que a marca não é apenas um rótulo, mas um indicador fundamental do valor percebido e do público-alvo de um veículo, criando uma estrutura de preços altamente segmentada no mercado automotivo [Aaker 1991].

3.3.2. Relação entre Marcas, Número de Bancos e Velocidade Total

Para aprofundar a análise sobre os diferentes posicionamentos na indústria automotiva, foi desenvolvido um gráfico de barras comparativo. Nele, as marcas são ordenadas de acordo com sua velocidade máxima média, permitindo uma visualização clara de sua performance. De forma justaposta, um segundo painel exibe o número médio de assentos para cada marca, oferecendo um panorama sobre o trade-off entre desempenho e utilidade, conforme mostrado na Figura 8.




Figura 8. Velocidade Máxima em função da Marca e Número de Assentos

O gráfico revela uma nítida correlação inversa entre velocidade e capacidade de passageiros, permitindo a identificação de três segmentos principais:

- **Superesportivos e Hiper carros:** O topo do ranking é dominado por marcas de nicho, como Bugatti, Lamborghini e Ferrari. Elas apresentam velocidades médias extraordinariamente altas (acima de 330 km/h) e, em contrapartida, a menor média de assentos, variando entre 2 e 2,9, caracterizando veículos focados exclusivamente em performance.
- **Luxo e Alta Performance:** Logo abaixo, encontra-se um segmento de marcas como Bentley, Porsche e Tesla, que combinam alto desempenho (entre 260 e 320 km/h) com maior versatilidade, oferecendo em média de 3,9 a 5,3 assentos. Este grupo demonstra um equilíbrio entre performance de elite e funcionalidade para mais passageiros.
- **Mercado Convencional:** A maior parte das marcas se concentra na faixa de velocidade entre 190 e 250 km/h, como Mercedes, Honda, Toyota e Chevrolet. Este grupo forma o núcleo do mercado de consumo, padronizando seus veículos com uma média de 5 a 6 assentos, priorizando a utilidade e o transporte familiar em detrimento da velocidade máxima.

Um caso notável, que a ordenação do gráfico destaca, é o da Volvo. A marca se posiciona no extremo inferior do ranking de velocidade, com uma média de 135,8 km/h, consideravelmente abaixo das demais. Essa característica, provavelmente um reflexo de políticas de segurança com limitação eletrônica de velocidade, demonstra como as estratégias e os valores de uma fabricante podem ser claramente visualizados através dos dados.

Dessa forma, a análise deste gráfico não apenas classifica as marcas por desempenho, mas também expõe suas diferentes filosofias de produto e os públicos aos quais se destinam.

3.3.3. Relação entre Preço e Desempenho

A análise bivariada entre o preço dos veículos e o tempo de aceleração de 0 a 100 km/h foi realizada por meio de um gráfico de dispersão com escala logarítmica no eixo do preço, conforme mostrado na Figura 9. A partir dos resultados observados, é possível identificar que não existe uma relação linear forte entre as duas variáveis. A linha de tendência apresentada no gráfico permanece praticamente horizontal, indicando que o preço dos veículos não aumenta ou diminui de forma diretamente proporcional ao tempo de aceleração.




Figura 9. Dispersão entre preço e tempo de aceleração de 0 a 100 km/h dos veículos

Observando o gráfico de linha de tendência por faixas de desempenho (Figura 10), percebe-se uma tendência geral fraca: modelos com tempos de aceleração menores (indicando maior desempenho) tendem a apresentar preços mais elevados. Esse comportamento sugere que veículos de alta performance geralmente pertencem a categorias esportivas ou de luxo. Ainda assim, a grande variabilidade dos preços em todas as faixas de desempenho demonstra que outros fatores, como marca, tecnologia embarcada, conforto e exclusividade, também exercem forte influência sobre o valor final de mercado.




Figura 10. Linha de tendência do preço em função do tempo de aceleração de 0 a 100 km/h

A utilização da escala logarítmica se mostrou essencial para a análise, uma vez que os preços apresentam ampla variação — desde modelos mais acessíveis até supercarros de altíssimo valor. Essa transformação permitiu uma visualização mais clara da distribuição dos dados e revelou que a maioria dos veículos está concentrada em uma faixa intermediária de preço, enquanto poucos modelos representam valores muito acima da média.

Em suma, a análise evidencia que o desempenho influencia o preço dos carros, mas essa relação é complexa e multifatorial, sendo necessária a consideração de outros atributos além da aceleração para compreender completamente a precificação dos veículos no mercado.

4. Considerações Finais

Conforme os dados apresentados, nossas análises corroboram de modo consistente as hipóteses e questionamentos iniciais. A seguir, retomamos cada um deles e destacamos as conclusões finais que emergem deste estudo.

4.1. Hipótese 1 – Preço, Marca e Especificações Técnicas

Observou-se que a marca é o principal fator determinante no valor de mercado de um veículo, superando especificações técnicas isoladas. A análise do preço médio por fabricante revelou uma hierarquia clara, com marcas de hiper carros (como Bugatti) em um patamar de preço exponencialmente superior, seguidas por marcas de luxo e, finalmente, por um grande grupo de fabricantes de volume.

Em contrapartida, a relação do preço com atributos como cavalos de potência e tempo de aceleração se mostrou fraca e não-linear. Isso demonstra que, embora a engenharia seja relevante, o prestígio, a exclusividade e o posicionamento da marca são os verdadeiros vetores da precificação no setor.

4.2. Hipótese 2 – Desempenho, Utilidade e Filosofia de Produto

Constatou-se uma correlação inversa e evidente entre performance e utilidade. Marcas focadas em alto desempenho (como Ferrari e Lamborghini) apresentam as maiores velocidades médias, mas, em contrapartida, a menor média de assentos (entre 2 e 3).

Em oposição, fabricantes do mercado de consumo padronizam seus veículos com 5 a 6 assentos, priorizando a funcionalidade em detrimento da velocidade máxima. Essa dinâmica expõe como a filosofia de produto de cada montadora — seja ela focada em esportividade pura ou em transporte familiar — molda diretamente as características técnicas de seus veículos, criando segmentos de mercado bem definidos.

4.3. Limitações e Estudos Futuros

A principal limitação deste estudo é a abrangência das variáveis, que não incluem dados sobre consumo de combustível, tecnologias de segurança, sistemas de infotainment ou qualidade de materiais, fatores que também influenciam o valor. Soma-se a isso o fato de o dataset ser um retrato estático de 2025, impedindo análises de tendências.

Para contornar essas restrições, recomenda-se, em estudos futuros, a incorporação de um conjunto de dados mais rico para a criação de modelos preditivos de preço e a realização de uma análise longitudinal com dados de múltiplos anos para mapear a evolução do mercado.

4.4. Síntese Final

Em suma, este trabalho demonstrou que o valor e a configuração de um veículo no mercado moderno são definidos por uma complexa interação entre engenharia, estratégia de marca e posicionamento de mercado. A análise quantitativa permitiu validar que, para além dos números de performance, é o valor intangível da marca que, em última instância, governa a estrutura de preços e a segmentação da indústria automotiva.

Referências

- [Aaker 1991] Aaker, D. A. (1991). *Managing Brand Equity*. The Free Press.
- [DeMuro 2018] DeMuro, D. (2018). Here's Why German Automakers Limit Their Cars to 155 Miles Per Hour. Autotrader. Acessado em 20 de setembro de 2025. Disponível em: <https://www.autotrader.com/car-news/heres-why-german-automakers-limit-their-cars-155-miles-hour-271549>.
- [Malik 2025] Malik, A. (2025). Cars dataset 2025. Kaggle. Disponível em: <https://www.kaggle.com/datasets/abdulmalik1518/cars-datasets-2025>.
- [Tukey 1977] Tukey, J. W. (1977). *Exploratory Data Analysis*. Addison-Wesley.

A. Anexo: Código de Análise em RStudio

Este anexo apresenta o código utilizado para as análises do dataset Cars Dataset 2025 no RStudio. Cada bloco de código está comentado para explicar sua função dentro do relatório.

A.1. Leitura e Exploração Inicial dos Dados

Listing 1. Leitura e estrutura do dataset

```
1 # --- Leitura do dataset ---
2 carros <- read.csv(file.choose(), stringsAsFactors = FALSE)
3
4 # --- Estrutura e nomes das colunas ---
5 str(carros)
6 names(carros)
```

Descrição: Carrega o dataset e mostra a estrutura e nomes das colunas.

A.2. Análise Univariada: Variáveis Qualitativas

A.2.1. Distribuição de Marcas

Listing 2. Distribuição de Marcas

```
1 # Tabela de frequencia da variavel 'marca'
2 table(carros$marca)
3 df_marcas <- as.data.frame(table(carros$marca))
4 colnames(df_marcas) <- c("marca", "freq")
5 df_marcas$marca <- reorder(df_marcas$marca, -df_marcas$freq)
6
7 # Grafico de barras das marcas
8 library(ggplot2)
9 ggplot(df_marcas, aes(x = marca, y = freq)) +
10   geom_bar(stat = "identity", fill = "tomato", color = "black") +
11   labs(title = "Distribuicao das Marcas (Ordenadas)",
12        x = "Marcas", y = "Frequencia") +
13   theme_minimal(base_size = 14) +
14   theme(axis.text.x = element_text(angle = 45, hjust = 1))
```

A.2.2. Distribuição de Tipos de Motor

Listing 3. Distribuição dos Tipos de Motor

```
1 # Tabela de frequencia para tipo de motor
2 table(carros$tipo_de_motor)
3 df_tipo_de_motor <- as.data.frame(table(carros$tipo_de_motor))
4 colnames(df_tipo_de_motor) <- c("tipo_de_motor", "freq")
5 df_tipo_de_motor$tipo_de_motor <- reorder(df_tipo_de_motor$tipo_de_motor, -
6     df_tipo_de_motor$freq)
7
8 # Grafico de barras
9 ggplot(df_tipo_de_motor, aes(x = tipo_de_motor, y = freq)) +
10   geom_bar(stat = "identity", fill = "tomato", color = "black") +
11   labs(title = "Distribuicao dos Tipos de Motores (Ordenados)",
12        x = "Tipos de Motores", y = "Frequencia") +
13   theme_minimal(base_size = 14) +
14   theme(axis.text.x = element_text(angle = 45, hjust = 1))
```

A.3. Análise Univariada: Variáveis Quantitativas

A.3.1. Número de Assentos

Listing 4. Número de Assentos

```
1 # Histograma e boxplot do numero de assentos
2 ggplot(carros, aes(x = factor(assentos))) +
3   geom_bar(fill = "tomato") +
4   labs(title = "Distribuicao Numero de Assentos",
5         x = "Numero de Assentos", y = "Frequencia") +
6   theme_minimal(base_size = 14)
7
8 ggplot(carros, aes(y = assentos)) +
9   geom_boxplot(fill = "lightblue", color = "black") +
10  labs(title = "Boxplot do Numero de Assentos",
11        y = "Numero de Assentos") +
12  theme_minimal(base_size = 14)
```

A.3.2. Desempenho (0–100 km/h)

Listing 5. Desempenho 0–100 km/h

```
1 # Limpeza e conversao da coluna 'performance'
2 carros$performance <- as.numeric(gsub(",", ".", carros$performance))
3
4 # Estatisticas descritivas
5 summary(carros$performance)
6 mean(carros$performance, na.rm = TRUE)
7 median(carros$performance, na.rm = TRUE)
8 sd(carros$performance, na.rm = TRUE)
9
10 # Histogramas + densidade
11 ggplot(carros, aes(x = performance)) +
12   geom_histogram(aes(y = ..density..), bins = 20, fill = "skyblue", color =
13     "black") +
14   geom_density(color = "blue", size = 1) +
15   labs(title = "Distribuicao do Tempo de Aceleracao (0 a 100 km/h)",
16         x = "Tempo (s)", y = "Densidade")
17
18 # Boxplot
19 ggplot(carros, aes(x = "", y = performance)) +
20   geom_boxplot(fill = "lightgreen", color = "black", outlier.color = "red",
21     outlier.size = 2) +
22   stat_summary(fun = mean, geom = "point", shape = 18, size = 3, color = "
23     blue") +
24   labs(title = "Boxplot do Tempo de Aceleracao (0 a 100 km/h)",
25         x = "", y = "Tempo (s)") +
26   theme_minimal(base_size = 14)
```

A.3.3. Potência dos Motores e Velocidade Máxima

Listing 6. Histograma e Boxplot da Potência dos Motores

```
1 # Histograma da potencia
2 ggplot(carros, aes(x = cavalo_potencia)) +
3   geom_histogram(binwidth = 20, fill = "orange", color = "tomato") +
4   labs(title = "Distribuicao da Potencia dos Motores",
5         x = "Cavalos de Potencia (HP)", y = "Frequencia") +
6   theme_minimal()
7
8 # Boxplot horizontal
9 ggplot(carros, aes(y = cavalo_potencia)) +
10  geom_boxplot(fill = "mediumseagreen", color = "black", alpha = 0.8) +
11  labs(title = "Resumo da Distribuicao de Potencia dos Motores",
12        x = "", y = "Cavalos de Potencia (HP)") +
13  coord_flip() +
14  theme_light()
```

A.3.4. Preço

Listing 7. Limpeza e Estatísticas do Preço

```
1 # Limpeza da coluna 'preco' e conversao para numerico
2 carros$preco <- gsub(",", "", carros$preco)
3 carros$preco <- gsub("\\$", "", carros$preco)
4 carros$preco <- gsub(" ", "", carros$preco)
5 carros$preco <- as.numeric(carros$preco)
6
7 # Estatisticas descritivas
8 summary(carros$preco)
9 mean(carros$preco, na.rm = TRUE)
10 median(carros$preco, na.rm = TRUE)
11 sd(carros$preco, na.rm = TRUE)
12
13 # Histograma com escala logaritmica
14 ggplot(carros, aes(x = preco)) +
15   geom_histogram(bins = 30, fill = "steelblue", color = "black", alpha =
16     0.7) +
17   scale_x_log10(labels = scales::comma) +
18   labs(title = "Distribuicao do Preco dos Carros (escala log10)",
19         x = "Preco (US$)", y = "Frequencia") +
20   theme_minimal(base_size = 14)
21
22 # Boxplot logaritmico
23 ggplot(carros, aes(x = "", y = preco)) +
24   geom_boxplot(fill = "lightgreen") +
25   stat_summary(fun = mean, geom = "point", shape = 18, size = 3, color = "
26     blue") +
27   scale_y_log10(labels = scales::comma) +
28   labs(title = "Boxplot do Preco dos Carros (escala log10)",
29         x = "", y = "Preco (US$)") +
30   theme_minimal()
```


A.4. Análise Bivariada

A.4.1. Marca vs Velocidade e Assentos

Listing 8. Comparativo de Velocidade e Assentos por Marca

```
1 library(tidyr)
2
3 df_resumo <- carros %>%
4   group_by(marca) %>%
5   summarise(media_velocidade = mean(velocidade_maxima, na.rm = TRUE),
6             media_assentos = mean(assentos, na.rm = TRUE)) %>%
7   arrange(media_velocidade)
8
9 df_resumo$marca <- factor(df_resumo$marca, levels = df_resumo$marca)
10
11 df_longo <- df_resumo %>%
12   pivot_longer(cols = c(media_velocidade, media_assentos),
13                names_to = "metrica", values_to = "valor")
14
15 ggplot(df_longo, aes(x = marca, y = valor, fill = metrica)) +
16   geom_col() +
17   geom_text(aes(label = round(valor, 1)), hjust = -0.1, size = 3.5) +
18   coord_flip() +
19   facet_wrap(~ metrica, scales = "free_x") +
20   labs(title = "Comparativo de Velocidade e Assentos por Marca",
21        x = "Marca", y = "Valor") +
22   theme_minimal(base_size = 14) +
23   theme(legend.position = "none")
```

A.4.2. Preço vs Desempenho

Listing 9. Dispersão e Tendência entre Preço e Desempenho

```
1 # Grafico de dispersao com escala logaritmica no preco
2 ggplot(carros, aes(x = performance, y = preco)) +
3   geom_point(alpha = 0.6, color = "pink") +
4   geom_smooth(method = "lm", se = FALSE, color = "steelblue", linetype = "
5     dashed") +
6   scale_y_log10(labels = scales::label_number(big.mark = ".", decimal.mark =
7     ",")) +
8   labs(title = "Relacao entre Preco e Desempenho (0 a 100 km/h)",
9        subtitle = "Em escala logaritmica",
10        x = "Tempo de aceleracao (s)", y = "Preco (US$)") +
11   theme_minimal(base_size = 14)
12
13 # Linha de tendencia por faixas de desempenho
14 faixas <- carros %>%
15   mutate(faixa_perf = cut(performance, breaks = seq(0, 35, by = 5))) %>%
16   group_by(faixa_perf) %>%
17   summarise(preco_medio = mean(preco, na.rm = TRUE))
18
19 ggplot(faixas, aes(x = faixa_perf, y = preco_medio)) +
20   geom_col(fill = "orange") +
21   scale_y_continuous(labels = scales::label_number(big.mark = ".", decimal.
22     mark = ",")) +
23   labs(title = "Preco Medio por Faixa de Desempenho",
24        x = "Faixa de tempo de aceleracao (s)", y = "Preco medio dos carros (
25     US$)") +
26   theme_minimal(base_size = 14)
```

B. Anexo: Frequência Absoluta e Relativa das Marcas de Veículos

Tabela 1. Frequência absoluta e relativa das marcas de veículos (ordenada).

Marca	Freq. Absoluta	Freq. Relativa (%)
Nissan	158	14,27%
Porsche	96	8,67%
Mazda	86	7,77%
Volkswagen	85	7,68%
Kia	63	5,69%
Chevrolet	58	5,24%
Mitsubishi	57	5,15%
GMC	53	4,79%
Peugeot	53	4,79%
Ford	31	2,80%
Toyota	31	2,80%
Rolls Royce	30	2,71%
Jaguar Land Rover	30	2,71%
Acura	27	2,44%
Lamborghini	24	2,17%
Tata Motors	24	2,17%
Mercedes	21	1,90%
Audi	21	1,90%
Cadillac	20	1,81%
Hyundai	19	1,72%
Jeep	19	1,72%
Volvo	12	1,08%
Aston Martin	11	0,99%
Bugatti	10	0,90%
Tesla	10	0,90%
Ferrari	9	0,81%
Honda	7	0,63%
Bentley	1	0,09%

C. Anexo: Medidas Resumo das Variáveis Quantitativas

Tabela 2. Medidas resumo das variáveis quantitativas.

Medida	Cavalo Potência	Velocidade Máx.	Performance	Preço(US\$)	Assentos
Média	307,6	215,1	16,2	119.876,6	4,8
Mediana	255,0	200,0	13,0	45.000,0	5,0
Moda	187,0	250,0	1,6	30.000,0	5,0
Mínimo	26,0	80,0	1,0	4.000,0	1,0
Máximo	1.850,0	500,0	31,0	18.000.000,0	12,0
Amplitude	1.824,0	420,0	30,0	17.996.000,0	11,0
Desvio Padrão	216,5	57,7	11,7	327.691,9	1,7
Q1 (25%)	148,0	180,0	6,0	28.000,0	4,0
Q3 (75%)	400,0	250,0	23,0	85.000,0	5,0