

# Análise Estatística de Dados Automotivos: Um Estudo Descritivo do Cars Dataset 2025

Juliana Miranda Bosio, Lucas Furlanetto Pascoali, Vinícios Rosa Buzzi

<sup>1</sup>Departamento de Informática e Estatística – Universidade Federal de Santa Catarina  
Caixa Postal 5094 – 88035-972 – Florianópolis – SC – Brazil

## 1. Introdução

O mercado automotivo contemporâneo é caracterizado por uma vasta diversidade de modelos, tecnologias e faixas de preço. A decisão de compra de um consumidor, assim como a estratégia de precificação de um fabricante, é influenciada por uma complexa interação de fatores, desde a potência do motor até o prestígio da marca.

Em um estudo preliminar (Trabalho 1- [Bosio et al. 2025]), foi realizada uma análise exploratória de dados [Tukey 1977] sobre o "Cars Dataset 2025" [Malik 2025]. Essa análise descritiva inicial revelou padrões importantes, como a forte assimetria na distribuição de preços, a dominância de certas categorias de motores (como "i4") e uma aparente correlação inversa entre performance (velocidade) e utilidade (número de assentos).

Este segundo trabalho avança da análise descritiva para a estatística inferencial. O objetivo central é utilizar testes de hipóteses para validar formalmente as observações. Para isso, definimos uma **Hipótese Nula** ( $H_0$ ), que representa o "status quo" (o que assumimos ser verdade), e uma **Hipótese Alternativa** ( $H_1$ ), que é o que queremos provar. Rejeitamos  $H_0$  se houver evidência estatística suficiente (ou seja, um  $p$ -valor  $\leq 0,05$ ) em favor da  $H_1$ .

As quatro hipóteses centrais investigadas foram:

- **Hipótese de Média (Potência):** Testar se a média de potência ( $\mu$ ) difere de 300 HP.
  - $H_0 : \mu = 300$
  - $H_1 : \mu \neq 300$
- **Hipótese de Proporção (Motores 'i4'):** Testar se a proporção ( $p$ ) de motores 'i4' é maior que 30%.
  - $H_0 : p \leq 0.30$
  - $H_1 : p > 0.30$
- **Hipótese de Correlação (Potência vs. Desempenho):** Testar se existe uma correlação negativa ( $\rho$ ) entre potência e tempo de aceleração.
  - $H_0 : \rho \geq 0$
  - $H_1 : \rho < 0$
- **Hipótese de Regressão (Preço vs. Potência):** Testar se o impacto da potência ( $\beta_1$ ) no preço é significativo.
  - $H_0 : \beta_1 = 0$
  - $H_1 : \beta_1 \neq 0$

Ao final, este trabalho visa oferecer um panorama claro e estatisticamente validado dos fatores que contribuem para a configuração do mercado automotivo.

## 2. Materiais e Métodos

Para a análise, o estudo concentrou-se em um subconjunto específico de variáveis. Foram selecionados os atributos considerados cruciais para quantificar as correlações entre as características técnicas dos automóveis (como motor e potência) e seus principais indicadores de valor e performance.

### 2.1. Tratamento e Preparação dos Dados

Antes de iniciar as análises, o dataset original passou por um processo de limpeza e preparação para garantir a qualidade e a consistência dos dados. As seguintes etapas foram executadas:

- **Tratamento de Valores Ausentes:** A integridade do dataset foi verificada, e optou-se pela remoção completa de registros que apresentassem dados faltantes em qualquer uma das colunas selecionadas para o estudo. Este procedimento resultou em um dataset final com 1107 observações, garantindo que todas as análises subsequentes fossem realizadas sobre um conjunto de dados completo.
- **Conversão de Tipos:** As colunas de natureza quantitativa (como preço, potência e número de assentos) foram convertidas de seu formato original de texto (string) para um formato numérico, permitindo a aplicação de operações matemáticas e estatísticas.
- **Normalização da Variável “Motor”:** A coluna original “motor” apresentava alta granularidade e falta de padronização. Para viabilizar uma análise consistente, foi criada uma nova variável qualitativa, “tipo\_de\_motor”, que agrupa e normaliza os registros em um conjunto de categorias predefinidas: i2, i3, i4, v6, v8, v10, v12, w16, vr6, 4 cilindradas, flat-4, flat-6, boxer-4, 3 cilindradas, mpfi, PMSM, hybrid, electric e Outros.

### 2.2. Descrição das Variáveis

#### 2.2.1. Tipo de Motor

- **Classificação:** Variável qualitativa nominal.
- **Descrição:** Categoria padronizada do motor, derivada da coluna original “motor” (*Engine*) conforme descrito na etapa de preparação.
- **Motivo de escolha:** Permite analisar de forma clara e objetiva a influência da motorização no preço e no desempenho dos veículos.

#### 2.2.2. Preço

- **Classificação:** Variável quantitativa contínua.
- **Descrição:** Preço de Varejo Sugerido pelo Fabricante, em dólares (USD). Refere-se à coluna *Price*.
- **Motivo de escolha:** Principal variável-alvo para os modelos de precificação e análises de valor.

#### 2.2.3. Desempenho

- **Classificação:** Variável quantitativa contínua.
- **Descrição:** Tempo, em segundos, que um carro leva para acelerar de 0 a 100 km/h, representado pela coluna *Performance*.
- **Motivo de escolha:** Permite comparações diretas com características como potência e número de assentos, facilitando a análise dos resultados.

#### 2.2.4. Cavalos de Potência

- **Classificação:** Variável quantitativa contínua.
- **Descrição:** Medida da potência do motor em cavalos-força (HP), referindo-se à coluna *HorsePower*.
- **Motivo de escolha:** Principal indicador de desempenho do veículo, fundamental para validar hipóteses relacionadas à performance.

#### 2.3. Métodos de Análise Inferencial

Para validar as hipóteses formuladas na introdução, este estudo emprega quatro testes estatísticos principais, selecionados com base na natureza das variáveis (quantitativas e qualitativas) e nos objetivos de cada hipótese. Em todos os testes, foi adotado um nível de significância ( $\alpha$ ) de 0,05.

- **Teste T para Média de uma Amostra:** Utilizado para verificar se a média populacional de cavalos de potência (HP) difere significativamente de um valor de referência (300 HP).
- **Teste de Proporção para uma Amostra:** Aplicado para determinar se a proporção observada de uma categoria de motor (ex: "i4") é estatisticamente superior a um percentual de mercado esperado (30%).
- **Teste de Correlação de Pearson:** Usado para quantificar e testar a significância da relação linear entre duas variáveis quantitativas contínuas: Cavalos de Potência (HP) e Desempenho (0-100 km/h).
- **Regressão Linear Simples:** Empregada para modelar a relação entre uma variável preditora (Cavalos de Potência) e uma variável resposta (Preço). Dada a forte assimetria positiva na distribuição de preços (identificada no Trabalho 1), uma transformação logarítmica ( $\log_{10}$ ) foi aplicada à variável Preço para melhor atender às suposições de linearidade e homocedasticidade do modelo. O teste foca na significância do coeficiente angular ( $\beta_1$ ) para determinar se a potência é um preditor linear válido para o logaritmo do preço.

Todas as análises foram conduzidas utilizando o software RStudio, e as suposições de cada teste (como a normalidade dos resíduos na regressão) foram avaliadas graficamente.

### 3. Resultados e Discussões

Nesta seção, são apresentados os resultados obtidos a partir da análise estatística do dataset. A apresentação está dividida em três partes: análise descritiva das variáveis qualitativas, quantitativas e bivariada. A análise foi conduzida sobre um conjunto de 1107 observações válidas.

#### 3.1. Estatísticas Descritivas

A análise descritiva inicial, documentada no Trabalho 1 [Bosio et al. 2025], revelou padrões fundamentais no conjunto de dados após o tratamento, resultando em 1107 observações válidas. Nas variáveis qualitativas, observou-se que 'Nissan' era a marca com maior frequência absoluta (158 modelos) e que os tipos de motor mais comuns eram 'i4', 'v6', 'v8' e 'electric'. A categoria 'i4', em particular, destacou-se como a configuração mais comum em carros de passeio.

As variáveis quantitativas apresentaram distribuições distintas. O 'Preço' exibiu uma forte assimetria à direita, com a maioria dos veículos concentrada na faixa de 30 a 300 mil dólares, mas com uma "cauda longa" de hiper carros que elevava a média. A 'Potência (HP)' seguiu um padrão similar de assimetria à direita, com a moda (pico de frequência) situando-se entre 160 e 200 HP. Em contrapartida, o 'Desempenho' (tempo de 0-100 km/h) teve uma distribuição relativamente uniforme, com média de 16,15 segundos, refletindo a diversidade da amostra, que ia de esportivos a utilitários.

A variável 'Número de Assentos' demonstrou uma clara moda em 5 assentos (com mais de 600 modelos), o padrão para veículos familiares, sedans e SUVs. Por fim, a 'Velocidade Máxima' apresentou um comportamento multimodal, com um pico notável e agudo exatamente em 250 km/h, identificado como um limite eletrônico padrão da indústria, especialmente alemã.

A análise bivariada descritiva também apontou uma forte correlação inversa entre 'Velocidade Máxima' e 'Número de Assentos' — validando o trade-off entre performance e utilidade. Além disso, confirmou que a 'Marca' é um fator hierárquico determinante para o preço, com valores médios que variam de dezenas de milhares (marcas de volume) a milhões de dólares (hiper carros como Bugatti).

#### 3.2. Teste de Média para Cavalos de Potência (HP)

O primeiro teste inferencial teve como objetivo verificar se a potência média ( $\mu$ ) dos veículos no dataset diferia significativamente de um valor de referência de 300 HP. Para isso, foram definidas as seguintes hipóteses, com um nível de significância  $\alpha = 0,05$ :

- **Hipótese Nula ( $H_0$ ):**  $\mu = 300$  (A média de potência é igual a 300 HP).
- **Hipótese Alternativa ( $H_1$ ):**  $\mu \neq 300$  (A média de potência é diferente de 300 HP).

Utilizando 1106 graus de liberdade ( $df$ ), a execução do Teste T para uma amostra (*One Sample t-test*) revelou que a média de potência (HP) observada na amostra ( $\bar{x}$ ) foi de **309,85 HP**. Este valor está, de fato, acima do valor hipotético de 300 HP.

A Figura 1 ilustra essa discrepância: a "Média da Amostra ( $\bar{x}$ )" (linha tracejada) está visivelmente à direita da "Média Hipotética ( $\mu$ )" (linha pontilhada). No entanto, o teste estatístico avalia se essa diferença é significativa ou se poderia ter ocorrido devido à variabilidade natural da amostragem.

O teste produziu um valor-t de 1,5335 e um **p-valor = 0,1254**. Logo, pela regra de decisão: para rejeitar a Hipótese Nula, o p-valor precisaria ser menor ou igual ao nível de significância ( $\alpha = 0,05$ ). Como **0,1254 (p-valor) > 0,05 ( $\alpha$ )**, a decisão estatística é **aceitar a Hipótese Nula ( $H_0$ )**.




Figura 1. Média para Carros de Potência

**Interpretação:** Em suma, não há evidência estatística suficiente, ao nível de significância de 5%, para afirmar que a média de potência dos carros no dataset seja diferente de 300 HP. Embora a média da amostra (309,85 HP) seja numericamente superior, a alta variabilidade e a forte assimetria dos dados (visíveis no histograma da Figura 1) indicam que essa diferença não é estatisticamente significativa. Em outras palavras, é plausível que a verdadeira média populacional seja 300 HP, e a diferença observada na amostra se deva ao acaso.

Esta conclusão é fortemente reforçada pelo **intervalo de confiança de 95%** fornecido pelo teste, que variou de **[297,25 HP a 322,45 HP]**. Como o valor da hipótese nula (300 HP) está contido dentro deste intervalo de valores plausíveis para a média, não podemos rejeitar  $H_0$ .

### 3.3. Teste de Proporção para Tipos de Motores

Para a segunda hipótese, foi investigado se a proporção ( $p$ ) de motores do tipo 'i4' era superior a 30% do total de veículos no dataset. Foi utilizado um teste de proporção unilateral, à nível de significância  $\alpha = 0,05$ , com as seguintes hipóteses:

- **Hipótese Nula ( $H_0$ ):**  $p \leq 0.30$  (A proporção de motores 'i4' é menor ou igual a 30%).
- **Hipótese Alternativa ( $H_1$ ):**  $p > 0.30$  (A proporção de motores 'i4' é maior que 30%).

A análise foi realizada sobre a variável 'tipo\_de\_motor'. O teste de proporção (*1-sample proportions test*) retornou uma proporção amostral ( $\hat{p}$ ) de **0.28455**, indicando que os motores 'i4' representam aproximadamente **28,5%** da amostra.

A Figura 2 ilustra este resultado, onde a barra destacada para o motor 'i4' (28,5%) não atinge a linha da Hipótese Nula, que está fixada em 30% (0.30).

O resultado estatístico do teste corrobora essa observação visual, no qual este gera um **p-valor = 0.8619**. Não obstante, a regra de decisão estabelece que a Hipótese Nula ( $H_0$ ) deve ser rejeitada se o p-valor for menor ou igual a  $\alpha$ . Como **0.8619 (p-valor) > 0,05 ( $\alpha$ )**, a decisão estatística é **aceitar a Hipótese Nula ( $H_0$ )**.




Figura 2. Proporção de motores i4


**Interpretação:** Não há evidência estatística suficiente, ao nível de significância de 5%, para suportar a afirmação de que a proporção de motores 'i4' no mercado seja superior a 30%. O valor p-valor extremamente alto (0.8619) indica que a proporção observada na amostra (28,5%) não é estatisticamente maior que 30%. Na verdade, por ser numericamente inferior, o resultado se alinha fortemente com a hipótese nula.

### 3.4. Análise de Correlação entre Potência e Desempenho

A terceira hipótese buscou validar a observação de que um aumento na potência (HP) levaria a uma diminuição no tempo de aceleração (0-100 km/h). Isso foi formalizado como um teste de correlação de Pearson, buscando uma correlação negativa ( $\rho$ ), a nível de significância  $\alpha = 0,05$ , as hipóteses testadas foram:

- **Hipótese Nula ( $H_0$ ):**  $\rho \geq 0$  (A correlação é positiva ou nula).
- **Hipótese Alternativa ( $H_1$ ):**  $\rho < 0$  (A correlação é negativa).

O Teste de Correlação de Pearson foi aplicado e o resultado da amostra produziu um coeficiente de correlação  $r = -0.0606$  (arredondado para -0.061 na Figura 3). Este valor, embora negativo, é extremamente próximo de zero, sugerindo uma relação linear muito fraca. O teste estatístico produziu um **p-valor = 0.02185**. A regra de decisão para este teste unilateral é rejeitar  $H_0$  se o p-valor for menor ou igual a  $\alpha$ . Como **0.02185 (p-valor) < 0,05 ( $\alpha$ )**, a decisão estatística é **rejeitar a Hipótese Nula ( $H_0$ )**.



**Figura 3. Correlação entre Potência e Desempenho**

**Interpretação:** Ao nível de significância de 5%, existe evidência estatística para concluir que a correlação entre a potência (HP) e o tempo de aceleração é negativa.

Contudo, este resultado exige uma interpretação cuidadosa. Embora o resultado seja *estatisticamente significativo* (o p-valor é baixo), a *significância prática* é quase nula. O coeficiente  $r = -0.061$  indica que menos de 1% da variabilidade no tempo de aceleração pode ser explicada linearmente pela potência.

A Figura 3 confirma visualmente esta conclusão: os pontos estão altamente dispersos, formando uma nuvem sem padrão linear claro. Embora a linha de tendência esteja levemente inclinada para baixo (consistente com  $r$  negativo), ela não serve como um bom modelo preditivo. Portanto, apesar da significância estatística, a potência (HP) sozinha não é um forte preditor linear para o desempenho de aceleração neste dataset.

### 3.5. Modelo de Regressão: Impacto da Potência no Preço do Veículo

A hipótese final testou se o impacto da potência (HP) sobre o preço do veículo é estatisticamente significativo. O modelo de Regressão Linear Simples foi empregado para testar o coeficiente angular ( $\beta_1$ ) da variável preditora (potência). O nível de significância foi mantido em  $\alpha = 0,05$ .

As hipóteses testadas foram:

- **Hipótese Nula ( $H_0$ ):**  $\beta_1 = 0$  (A potência não tem efeito linear significativo sobre o preço).
- **Hipótese Alternativa ( $H_1$ ):**  $\beta_1 \neq 0$  (A potência tem um efeito linear significativo sobre o preço).

Conforme observado na análise exploratória (Trabalho 1 - [Bosio et al. 2025]) e confirmado pela Figura 4, a variável preço possui uma forte assimetria positiva. Para estabilizar a variância e linearizar a relação, foi aplicado um modelo Log-Linear, utilizando o  $\log_{10}(\text{Preço})$  como variável resposta. A saída do sumário do modelo (`lm(formula = log10(preço) ~ cavalo_potencia)`) forneceu os seguintes resultados-chave:

- **Coefficiente ( $\beta_1$ ):** A estimativa para `cavalo_potencia` foi de **0.0018348**. O sinal positivo indica que, como esperado, um aumento na potência está associado a um aumento no  $\log_{10}(\text{Preço})$ .
- **P-valor:** O p-valor associado ao coeficiente  $\beta_1$  foi reportado como **< 2.2e-16**.

A regra de decisão é rejeitar  $H_0$  se o p-valor for menor ou igual a  $\alpha$ .

Como  $< 2.2\text{e-}16$  (p-valor)  $\ll 0,05$  ( $\alpha$ ), a decisão estatística é **rejeitar a Hipótese Nula ( $H_0$ )** com extrema confiança.




Figura 4. Modelo de Regressao




Figura 5. Análise Residual

**Interpretação:** Existe uma evidência estatística avassaladora de que a potência (HP) é um preditor linear significativo e positivo para o logaritmo do preço dos veículos. A qualidade do modelo é reforçada pelo **Multiple R-squared = 0.8195**, indicando que **81,95%** da variabilidade no  $\log_{10}(\text{Preço})$  é explicada pela variável potência (HP). A Figura 4 ilustra essa forte relação positiva, com a linha de regressão se ajustando bem à nuvem de pontos.

Contudo, é crucial notar que a análise residual (Figura 5) revela limitações no modelo. O gráfico "Q-Q Residuals" (canto superior direito), em particular, apresenta desvios significativos nas caudas, com resíduos mais extremos (tanto positivos quanto negativos) do que o esperado por uma distribu-



ição normal. Isso indica que, embora o modelo *log-linear* seja uma excelente aproximação para a maioria dos dados (explicando 81,95% da variância), ele falha em capturar perfeitamente o comportamento dos veículos nos extremos de preço (os muito baratos ou os supercarros), sugerindo que a suposição de normalidade dos erros não é completamente atendida.

Adicionalmente, a análise residual (Figura 5) valida as suposições do modelo: o gráfico "*Q-Q Residuals*" mostra que os resíduos seguem uma distribuição aproximadamente normal, e o gráfico "*Residuals vs Fitted*" mostra uma dispersão aleatória dos pontos em torno do zero, indicando homocedasticidade (variância constante dos erros) e uma boa adequação da forma linear.

## 4. Considerações Finais

Este segundo trabalho avançou da análise descritiva (previamente realizada no Trabalho 1) para a estatística inferencial, com o objetivo central de validar formalmente quatro hipóteses sobre o "Cars Dataset 2025"[Malik 2025], utilizando um nível de significância  $\alpha = 0,05$ .

Os resultados dos testes de hipóteses forneceram um panorama claro, confirmando algumas observações, mas refutando outras:

- **Hipótese de Média (Potência):** Falhou-se em rejeitar a Hipótese Nula ( $H_0 : \mu = 300$ ). O p-valor de 0,1254 indica que, embora a média da amostra ( $\bar{x} = 309,85$  HP) tenha sido numericamente superior, ela não é *estatisticamente* diferente do valor de referência de 300 HP. O valor hipotético de 300 estava contido no intervalo de confiança de 95%, reforçando esta conclusão.
- **Hipótese de Proporção (Motores 'i4'):** Também se falhou em rejeitar a Hipótese Nula ( $H_0 : p \leq 0.30$ ). A proporção observada de motores 'i4' foi de 28,5%[cite: 96], um valor numericamente inferior ao testado. Com um p-valor de 0.8619, não há evidência estatística para suportar a afirmação de que a proporção destes motores seja superior a 30%.
- **Hipótese de Correlação (Potência vs. Desempenho):** A Hipótese Nula ( $H_0 : \rho \geq 0$ ) foi rejeitada (p-valor = 0.02185). Contudo, este resultado exemplifica a diferença entre significância estatística e prática. O coeficiente  $r = -0.061$ [cite: 114], embora estatisticamente negativo, é tão próximo de zero que indica uma relação linear praticamente inexistente, como validado pela nuvem de pontos altamente dispersa na Figura 3.
- **Hipótese de Regressão (Preço vs. Potência):** Este foi o resultado mais robusto. A Hipótese Nula ( $H_0 : \beta_1 = 0$ ) foi rejeitada com confiança avassaladora (p-valor  $< 2.2e-16$ ). A potência (HP) provou ser um preditor linear altamente significativo para o logaritmo do preço, com o modelo explicando **81,95%** da variância (R-squared = 0.8195).

É crucial, no entanto, notar as limitações do modelo de regressão. A análise residual (Figura 5) revelou que a suposição de normalidade dos erros não foi perfeitamente atendida. O gráfico "Q-Q Residuals"[cite: 168-175], especificamente, mostrou desvios notáveis nas caudas (apresentando "caudas pesadas"), indicando que o modelo log-linear, embora robusto para a tendência central, tem dificuldade em modelar com precisão os veículos nos extremos de preço (os muito baratos ou os supercarros).

Para trabalhos futuros, seria recomendado investigar modelos de regressão mais avançados (como regressão robusta ou modelos não lineares) que possam acomodar melhor essa distribuição de erros, aprimorando a previsibilidade do modelo. Este estudo, por fim, demonstra a importância da estatística inferencial, não apenas para confirmar padrões, mas para quantificar sua significância e expor as limitações de nossas suposições.

## Referências

- [Bosio et al. 2025] Bosio, J., Pascoali, L., and Buzzi, V. (2025). Um estudo descritivo do cars dataset 2025. Trabalho 1 da disciplina INE5405. Disponível em: <https://github.com/julianamirbosio/INE5405>.
- [Malik 2025] Malik, A. (2025). Cars dataset 2025. Kaggle. Disponível em: <https://www.kaggle.com/datasets/abdulmalik1518/cars-datasets-2025>.
- [Tukey 1977] Tukey, J. W. (1977). *Exploratory Data Analysis*. Addison-Wesley.

## A. Anexo: Código de Análise em RStudio da Análise Inferencial

Este anexo apresenta os códigos utilizados para a análise inferencial (testes de hipóteses) do dataset Cars Dataset 2025 no RStudio. O script foi organizado de forma sequencial: um bloco inicial carrega e limpa todos os dados necessários, e os blocos subsequentes executam cada um dos quatro testes solicitados.

### A.1. Carregamento e Preparação dos Dados

Listing 1. Carregar bibliotecas, ler e limpar dados globais

```
1 # --- 1. Carregar Bibliotecas (Uma vez) ---
2 library(ggplot2)
3 library(scales)
4 library(dplyr) # Necessario para Teste de Proporcão e Regressão
5
6 ## --- 2. Leitura dos dados ---
7 # Usando encoding UTF-8 para garantir a leitura correta dos nomes
8 carros <- read.csv(file.choose(), stringsAsFactors = FALSE, encoding = "UTF
  -8")
9
10 # --- 3. Limpeza dos Dados (Global) ---
11
12 # Limpeza para Teste T, Correlação e Regressão
13 carros$cavalo_potencia <- gsub(",", "", carros$cavalo_potencia)
14 carros$cavalo_potencia <- as.numeric(carros$cavalo_potencia)
15
16 # Limpeza para Teste de Correlação
17 carros$performance <- gsub(",", ".", carros$performance)
18 carros$performance <- as.numeric(carros$performance)
19
20 # Limpeza para Teste de Regressão
21 carros$preco <- gsub("\\$", "", carros$preco)
22 carros$preco <- gsub(",", "", carros$preco)
23 carros$preco <- gsub(" ", "", carros$preco)
24 carros$preco <- as.numeric(carros$preco)
25
26 # Exibe a estrutura dos dados limpos (opcional)
27 str(carros)
```

### A.2. Teste T para Média de Cavalos de Potência (HP)

Listing 2. Teste T para Média de Cavalos de Potência (HP)

```
1 # --- 1. Preparar dados locais ---
2 # (Assume que 'carros' já foi carregado e limpo)
3 hp_limpo <- na.omit(carros$cavalo_potencia)
4
5 # --- 2. Executar o Teste T para Média de uma Amostra ---
6 # H0: mu = 300
7 # H1: mu != 300
8 valor_referencia_mu <- 300
9
10 teste_media <- t.test(hp_limpo,
11                       mu = valor_referencia_mu,
12                       alternative = "two.sided")
13
14 # --- 3. Exibir os resultados do teste no console ---
15 print(teste_media)
16
```

```

17 # --- 4. GERAR O GRAFICO DE APOIO ---
18 hp_df <- data.frame(potencia = hp_limpo)
19 media_amostra <- teste_media$estimate
20
21 linhas_info <- data.frame(
22   Tipo = c("Media Hipotetica (mu)", "Media da Amostra (x)"),
23   Valor = c(valor_referencia_mu, media_amostra)
24 )
25
26 # Criar o grafico (Versao Limpa)
27 ggplot(hp_df, aes(x = potencia)) +
28   geom_histogram(aes(y = ..density..), binwidth = 25, fill = "steelblue",
29     color = "black", alpha = 0.7) +
30   geom_density(col = "blue", size = 1) +
31   geom_vline(data = linhas_info,
32     aes(xintercept = Valor, color = Tipo, linetype = Tipo),
33     size = 1.2) +
34
35   scale_color_manual(values = c("Media Hipotetica (mu)" = "tomato", "Media
36     da Amostra (x)" = "darkgreen")) +
37   scale_linetype_manual(values = c("Media Hipotetica (mu)" = "dotted", "
38     Media da Amostra (x)" = "dashed")) +
39
40   coord_cartesian(xlim = c(0, 800)) +
41
42   labs(title = "Visualizacao do Teste T: Potencia dos Carros",
43     subtitle = "Distribuicao da Potencia (HP) vs. Media Hipotetica (300
44       HP)",
45     x = "Cavalos de Potencia (HP)",
46     y = "Densidade",
47     color = "Legenda",
48     linetype = "Legenda") +
49   theme_minimal() +
50   theme(legend.position = "top")

```

### A.3. Teste de Proporção para Tipos de Motores

Listing 3. Teste de Proporção para Motores 'i4' ( $H_0: p \leq 0.30$ )

```
1 # --- 1. Preparar dados locais ---
2 # (Assume que 'carros' ja foi carregado)
3 motores_limpo <- na.omit(carros$tipo_de_motor)
4 motores_limpo <- motores_limpo[motores_limpo != ""]
5
6 # --- 2. Calcular 'n' e 'x' para o teste ---
7 n <- length(motores_limpo)
8 x <- sum(motores_limpo == "i4")
9
10 # --- 3. Definir a Hipotese ---
11 # H0: p <= 0.30
12 # H1: p > 0.30
13 valor_proporcao_h0 <- 0.30
14
15 # --- 4. Executar o Teste de Proporcao ---
16 teste_proporcao <- prop.test(x = x,
17                             n = n,
18                             p = valor_proporcao_h0,
19                             alternative = "greater",
20                             correct = TRUE)
21
22 # --- 5. Exibir os resultados completos do teste ---
23 print(teste_proporcao)
24
25 # --- 6. GERAR GRAFICO DE APOIO ---
26 prop_motores_df <- data.frame(tipo_de_motor = motores_limpo) %>%
27   count(tipo_de_motor) %>%
28   mutate(
29     proporcao = n / sum(n),
30     destaque = ifelse(tipo_de_motor == "i4", "Destaque (i4)", "Outros")
31   )
32
33 # Plotar o grafico de barras de proporcao
34 ggplot(prop_motores_df, aes(x = reorder(tipo_de_motor, -proporcao), y =
35   proporcao, fill = destaque)) +
36   geom_bar(stat = "identity", color = "black") +
37   geom_hline(yintercept = valor_proporcao_h0,
38             linetype = "dashed",
39             color = "#e41a1c", # Vermelho
40             size = 1.2) +
41
42   annotate(geom = "text",
43           x = 5,
44           y = 0.32,
45           label = paste("H0: p =", valor_proporcao_h0),
46           color = "#e41a1c",
47           fontface = "bold") +
48
49   scale_y_continuous(labels = scales::percent_format(accuracy = 1)) +
50
51   scale_fill_manual(values = c("Destaque (i4)" = "steelblue", "Outros" = "
52     grey80")) +
53
54   labs(title = "Visualizacao do Teste de Proporcao: Motores 'i4'",
55        subtitle = paste("Proporcao Observada (", round(teste_proporcao$
56          estimate * 100, 1), "%) vs. Hipotese Nula (30%)"),
```

```
55     x = "Tipo de Motor",
56     y = "Proporcao no Dataset") +
57
58 theme_minimal() +
59 theme(axis.text.x = element_text(angle = 60, hjust = 1),
60       legend.position = "none")
```

## A.4. Teste de Correlação (Potência vs. Desempenho)

Listing 4. Teste de Correlação (Potência vs. Desempenho)

```
1 # --- 1. Preparar dados locais ---
2 # (Assume que 'carros' já foi carregado e limpo)
3 carros_corr_limpo <- na.omit(carros[, c("cavalo_potencia", "performance")])
4
5 # --- 2. Definir a Hipotese ---
6 # H0: A correlacao (rho) e >= 0
7 # H1: A correlacao (rho) e < 0
8
9 # --- 3. Executar o Teste de Correlacao de Pearson ---
10 teste_corr <- cor.test(~ cavalo_potencia + performance,
11                        data = carros_corr_limpo,
12                        method = "pearson",
13                        alternative = "less")
14
15 # --- 4. Exibir os resultados completos do teste ---
16 print(teste_corr)
17
18 # --- 5. GERAR GRAFICO DE APOIO ---
19 valor_r <- teste_corr$estimate
20
21 ggplot(carros_corr_limpo, aes(x = cavalo_potencia, y = performance)) +
22   geom_point(alpha = 0.4, color = "steelblue") +
23   geom_smooth(method = "lm", col = "#e41a1c", fill = "grey80") +
24   scale_x_log10(labels = scales::comma) +
25   labs(title = "Correlacao: Potencia (HP) vs. Desempenho (0-100 km/h)",
26        subtitle = paste("Correlacao de Pearson (r) =", round(valor_r, 3)),
27        x = "Cavalos de Potencia (HP) - (Eixo logaritmico)",
28        y = "Tempo de Aceleracao (segundos)") +
29   theme_minimal()
```



## A.5. Teste de Regressão Linear (Preço vs. Potência)

Listing 5. Teste de Regressão Linear (Preço vs. Potência)

```
1 # --- 1. Preparar dados locais ---
2 # (Assume que 'carros' já foi carregado e limpo)
3 carros_reg <- na.omit(carros[, c("preco", "cavalos_potencia")])
4
5 # --- 2. Modelo Log-Linear (RECOMENDADO) ---
6 # (Baseado na análise exploratória do Trabalho 1)
7
8 # Construir o modelo log-linear (log10 do preco)
9 modelo_log <- lm(log10(preco) ~ cavalos_potencia, data = carros_reg)
10
11 # Analisar o modelo log-linear
12 print(summary(modelo_log))
13
14 # Plotar o modelo log-linear
15 ggplot(carros_reg, aes(x = cavalos_potencia, y = preco)) +
16   geom_point(alpha = 0.5, color = "pink") +
17   geom_smooth(method = "lm", col = "steelblue", linetype = "dashed", formula
18     = y ~ x) +
19   scale_y_log10(labels = scales::comma) +
20   labs(title = "Regressao: Preco (Log) vs. Potencia",
21     subtitle = "Eixo Y em escala logaritmica (log10)",
22     x = "Cavalos de Potencia (HP)",
23     y = "Preco (US$)") +
24   theme_minimal()
```